

TECNOLÓGICO DE MONTERREY

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador — Reporte de Avance 1

Programa Voces: Caracterización del corpus, estado del prototipo y plan técnico del modelo NMT Bribri-Español

Iniciativa intercultural sin fines de lucro · Territorio Indígena Bribri de Talamanca, Costa Rica

Profesora titular

Dra. Gretel Barceló — Directora de la M.Sc. en IA Aplicada

Integrantes del equipo

Daniel Leiva Sanabria

Encargado Regional Costa Rica · Programa Voces

Matrícula: A01795876

Israel Agustín Vargas Monroy

Responsable de Implementación · Programa Voces

Matrícula: A01796556

Patrocinador institucional

Carlos Aspillaga — Director del Programa Voces
Centro Nacional de Inteligencia Artificial (CENIA), Chile

Mayo de 2026

ÍNDICE

El siguiente índice se genera automáticamente. En Microsoft Word, hacer clic derecho → "Actualizar campos".

ÍNDICE	2
1. INTRODUCCIÓN Y RECONCILIACIÓN CON FASE 1	3
1.1 Propósito del presente reporte.....	3
1.2 Precisión metodológica respecto a Fase 1	3
1.3 Adaptación del entregable a la rúbrica del curso	3
2. CARACTERIZACIÓN DEL CORPUS	4
2.1 Fuentes documentales disponibles al momento de este reporte.....	4
2.2 Inventario y categorización técnica.....	4
2.3 Estimación de pares paralelos extraíbles.....	5
2.4 Brechas respecto a Fase 1 y plan de recuperación	6
2.5 Pipeline de preprocesamiento previsto	7
2.6 Estrategia frente al sesgo de dominio.....	7
3. COMPONENTE A — INTERFAZ DE VALIDACIÓN COMUNITARIA	8
3.1 Naturaleza técnica del componente.....	8
3.2 Recursos lingüísticos integrados como contexto	8
3.3 Mecanismo de retroalimentación humana	8
3.4 Validación preliminar en territorio	8
3.5 Posicionamiento en el ecosistema del proyecto.....	9
4. COMPONENTE B — MODELO NMT (CONTRIBUCIÓN ACADÉMICA)	9
4.1 Delimitación del aporte académico	9
4.2 Selección de arquitectura	9
4.3 Estrategia de tokenización.....	10
4.4 Plan de entrenamiento y cómputo	10
4.5 Marco de evaluación	10
4.6 Framework de comparación con Componente A	11
5. HALLAZGOS DEL TRABAJO DE CAMPO	12
5.1 Implicaciones técnicas y metodológicas	12
6. RIESGOS Y DEPENDENCIAS	13
7. CRONOGRAMA AJUSTADO AL CIERRE ACADÉMICO.....	13
8. BIBLIOGRAFÍA	14

1. INTRODUCCIÓN Y RECONCILIACIÓN CON FASE 1

1.1 Propósito del presente reporte

El presente documento constituye el Reporte de Avance 1 del Proyecto Integrador correspondiente a la Maestría en Inteligencia Artificial Aplicada del Tecnológico de Monterrey, en continuidad con la propuesta de Fase 1 entregada y aprobada en mayo de 2026. Conforme a la rúbrica adaptada al dominio de traducción automática neuronal acordada con la dirección del programa, este reporte concentra su contenido en tres ejes: caracterización técnica del corpus disponible, descripción del estado actual del prototipo, y plan técnico del modelo NMT a desarrollar como contribución académica del equipo de Costa Rica.

1.2 Precisión metodológica respecto a Fase 1

La propuesta de Fase 1 posicionó como solución técnica un sistema de traducción automática neuronal basado en arquitecturas Transformer, con fine-tuning sobre modelos multilingües preentrenados. En el transcurso de las operaciones de campo desarrolladas durante abril y mayo de 2026, y en articulación con el equipo de implementación del Programa Voces en Chile, la arquitectura técnica del proyecto ha sido precisada en un marco híbrido de dos componentes complementarios:

- Componente A — Interfaz de validación comunitaria: un sistema de tipo wrapper sobre un modelo de lenguaje grande pre-existente, desarrollado por el equipo de implementación de CENIA en Chile, que utiliza prompt engineering con augmentación documental para entregar traducciones a la comunidad y habilitar la recolección de retroalimentación humana en territorio.
- Componente B — Modelo NMT con fine-tuning sobre arquitectura Transformer: contribución técnica del equipo de Costa Rica (D. Leiva, I. Vargas), entrenado con cómputo de CENIA, evaluado cuantitativa y cualitativamente, y posicionado como aporte académico del Proyecto Integrador al ecosistema del Programa Voces.

Esta precisión no constituye un cambio de proyecto, sino una clarificación de roles dentro de un mismo equipo intercultural multi-institucional. Ambos componentes comparten corpus, criterios de evaluación y protocolos de propiedad comunitaria; se separan en la capa de ejecución técnica y en la atribución de aportes. El entregable académico evaluado por el Tecnológico de Monterrey corresponde específicamente al Componente B, valorado en comparación con el Componente A como línea base de producción.

1.3 Adaptación del entregable a la rúbrica del curso

De común acuerdo con la dirección académica del programa, la rúbrica original del Avance 1, centrada en un análisis exploratorio de datos (EDA) tradicional, ha sido adaptada al dominio específico de traducción automática para lenguas de bajos recursos. La adaptación reemplaza el EDA tabular por una caracterización técnica del corpus orientada a las decisiones de

modelado en NMT: estructura bilingüe de las fuentes, viabilidad de alineación oración por oración, sesgo de dominio, calidad de extracción y plan de preprocesamiento. Esta caracterización conserva el rigor metodológico exigido por la rúbrica original y lo redirige a los criterios de calidad efectivamente relevantes para el ciclo CRISP-ML aplicado a NMT.

2. CARACTERIZACIÓN DEL CORPUS

2.1 Fuentes documentales disponibles al momento de este reporte

El corpus disponible para el proyecto al momento de redacción de este reporte está compuesto por diez documentos primarios, totalizando aproximadamente 1.950 páginas, gestionados a través del repositorio compartido del Programa Voces. Estas fuentes han sido inspeccionadas técnicamente una por una con el objetivo de caracterizar de manera precisa su estructura bilingüe efectiva, su extractabilidad mediante herramientas estándar de procesamiento de PDF y su valor real como aporte al corpus paralelo bribri-español.

La inspección técnica revela una diferencia importante respecto al enunciado de las fuentes en la sección 3.1 de Fase 1: no todas las fuentes mencionadas en la propuesta inicial están efectivamente disponibles en el repositorio del proyecto al día de hoy, y la naturaleza bilingüe de varias fuentes disponibles es menos paralelizable de lo inicialmente anticipado. La sección 2.4 documenta las brechas y el plan de recuperación.

2.2 Inventario y categorización técnica

La Tabla 1 resume la caracterización técnica de cada documento tras inspección directa. La columna "Estructura bilingüe" describe la modalidad concreta en que el contenido bribri y español se encuentran organizados, y constituye el factor determinante para la viabilidad de extracción de pares paralelos.

Tabla 1 · Inventario y caracterización técnica del corpus disponible.

Documento	Pág.	Naturaleza tras inspección técnica	Estructura bilingüe	Valor para NMT y observaciones
Gramática de la lengua bribri (Jara Murillo, 2018)	286	Gramática descriptiva académica con extensa colección de ejemplos.	Ejemplos interlineales de tres líneas: bribri / glosa morfológica / traducción libre al español.	Alto. Extracción automática viable. Estimado 800–1.500 pares cortos. Texto seleccionable.
Sé'ttö' bribri ie · Hablemos en Bribri (Jara Murillo y García Segura, 2013)	189	Libro de texto bilingüe para enseñanza del bribri.	Diálogos y oraciones paralelas con marcadores explícitos de traducción.	Muy alto. Registro didáctico-conversacional. Estimado 500–1.000 pares. Texto seleccionable.
I ttè — Historias bribris (Jara)	207	Compilación de historias de tradición oral bribri con estudio introductorio.	Cada historia presenta texto bribri y versión en español como secciones	Alto, con preprocesamiento. Registro narrativo tradicional.

Documento	Pág.	Naturaleza tras inspección técnica	Estructura bilingüe	Valor para NMT y observaciones
Murillo, 1993, 2. ^a ed. digital)			separadas; requiere alineación posterior.	Estimado 300–600 pares tras alineación.
Ditsò rukuò — Identidad de las semillas (García Segura y Sylvester)	88	Narrativa cultural en torno a la cosmovisión bribri.	Trilingüe (bribri / español / inglés) con secciones paralelas por relato.	Medio-alto. Corpus pequeño pero de alta calidad. Texto seleccionable.
Las palabras de Francisco García (Jara Murillo y García Segura, comp.)	187	Compilación de cartas, obituarios y transcripciones de grabaciones del awá Francisco García.	Parte I monolingüe español. Parte II con transcripciones interlineales bribri-glosa-español.	Alto en la parte II. Estimado 150–400 pares. Registro oral tradicional.
La traducción de Gabb del Evangelio según san Juan al bribri, Vol. 1 (Sánchez Avendaño, 2025)	412	Edición filológica comentada de la traducción decimonónica de Gabb, con procesamiento lingüístico moderno.	Cinco líneas alineadas por versículo: bribri antiguo (Gabb), glosa morfológica, bribri moderno regularizado, Reina-Valera, retraducción al español moderno.	Alto en volumen, pero registro religioso arcaico. Estimado 800–1.200 versículos. Requiere control de dominio en entrenamiento.
Diccionario de mitología bribri (Editorial UCR)	333	Diccionario temático con entradas léxicas y definiciones extensas.	Pares lexicales: entrada bribri → definición en español. PDF escaneado, requiere OCR especializado.	Medio. Aporta léxico cultural; no provee oraciones paralelas. OCR no trivial por diacríticos.
Kó Késka — El lugar del tiempo (Jara Murillo y García Segura, 1997)	108	Compilación de historias y tradiciones orales con introducción extensa.	Primariamente narrativa en español con términos bribri inserto. Sin paralelización sistemática observada. PDF escaneado.	Bajo como corpus paralelo. Útil como referencia contextual.
Cargos tradicionales del pueblo bribri	194	Compendio etnográfico sobre roles tradicionales (uséköl, awá, bikákla, sïö'tāmi).	Texto monolingüe español con terminología bribri en cursiva, sin traducciones paralelas.	Bajo como corpus paralelo. Útil para vocabulario cultural y léxico especializado.
Se' dör stë (García Segura)	114	Ensayos sobre cosmovisión y derechos indígenas bribris.	Bilingüe español-inglés con expresiones bribri ocasionales como ornamento. No es corpus bribri-español.	Muy bajo como corpus paralelo del par objetivo.

2.3 Estimación de pares paralelos extraíbles

La integración de las estimaciones por documento arroja un total realista de pares paralelos bribri-español extraíbles del corpus actualmente disponible en el rango de 2.500 a 4.500 pares, una vez completado el pipeline de extracción, normalización y alineación. Esta cifra revisa a la baja la estimación de "decenas de miles de pares de oraciones" indicada en la sección 3.1.3 de Fase 1. La revisión responde a tres factores constatados en la inspección técnica:

- Tres documentos clave de Fase 1 (Krohn, Margery Peña, materiales del MEP) no están efectivamente disponibles en el repositorio del proyecto al día de redacción de este reporte.
- Tres documentos disponibles (Diccionario de mitología, Kó Késka, Cargos tradicionales) son escaneos o requieren OCR especializado, con desafíos adicionales por la marcación de tonos, vocales nasales y cortes glotales propios de la ortografía bribri estandarizada.
- Dos documentos disponibles (Cargos tradicionales, Se' dör stë) son sustancialmente monolingües en español o bilingües español-inglés, sin paralelización efectiva con bribri.

Esta estimación es coherente con el rango típico de corpus paralelos para lenguas de bajos recursos documentadas en la literatura de NMT para lenguas indígenas americanas (Mager et al., 2018; Ortega et al., 2020) y orienta el diseño técnico del Componente B hacia estrategias específicas de fine-tuning con corpus reducido sobre modelos multilingües preentrenados.

2.4 Brechas respecto a Fase 1 y plan de recuperación

Las siguientes fuentes mencionadas en la sección 3.1.1 de Fase 1 no se encuentran al día de hoy en el repositorio operativo del proyecto y requieren un plan explícito de recuperación:

- Diccionario bribri-español de Haakon Krohn.
- Diccionario fraseológico bribri-español, español-bribri (Margery Peña, 1989).
- Materiales del Subsistema de Educación Indígena del Ministerio de Educación Pública (MEP).

Adicionalmente, se documenta como recurso externo de exploración no aún incorporado al pipeline:

- Sitio web lenguabribri.com, identificado como repositorio potencialmente paralelo.
- Corpus Pandialectal Oral, identificado como referencia académica potencial.

El plan de recuperación se articula en tres frentes:

- Vía UCR: contacto formal con la red académica del Dr. Carlos Sánchez Avendaño (editor del corpus ESSJ) y de la Dra. Carla Victoria Jara Murillo (autora de la Gramática y de I ttë) para acceder a las ediciones digitales o autorizaciones de uso de Krohn y Margery Peña.

- Vía MEP: aprovechamiento de los canales abiertos durante el trabajo de campo en Talamanca (3-5 de mayo) y el contacto con CCSS (5 de mayo) para acceder a materiales del Subsistema de Educación Indígena.
- Vía Programa Voces: solicitud al equipo de CENIA en Chile sobre los recursos integrados en el ecosistema del programa que pudieran complementar el repositorio local.

2.5 Pipeline de preprocesamiento previsto

El pipeline de preprocesamiento del corpus se ha diseñado en cuatro etapas, replicables y trazables conforme al ciclo CRISP-ML:

- Normalización ortográfica: consolidación Unicode, normalización de marcadores tonales (acentos circunflejos invertidos y agudos), vocales nasales con virgulilla, cortes glotales con apóstrofo, según la convención ortográfica de Constenla-Margery-Jara.
- Alineación oración por oración: para los documentos con bribri y español en secciones separadas (I ttè, Sé'ttö' bribri ie, Ditsò rukuò), aplicación de alineadores estadísticos clásicos como hunalign o LASER multilingual sentence embeddings para alineación basada en similitud semántica multilingüe.
- Aseguramiento de calidad: muestreo estratificado de pares alineados para revisión por hablantes nativos y lingüistas colaboradores (UCR), con criterios de aceptación/rechazo/observación documentados.

2.6 Estrategia frente al sesgo de dominio

Una constatación importante de la caracterización del corpus es que el material disponible está fuertemente sesgado hacia los registros narrativo tradicional, religioso y etnográfico, sin cobertura sustantiva de los registros clínico, escolar formal y administrativo, que son justamente los casos de uso institucionales declarados en las secciones 2.2 y 2.3 de Fase 1 (CCSS, MEP, trámites institucionales). Este desbalance es propio de la situación documental de la lengua y no es atribuible al diseño del proyecto, pero exige una estrategia explícita para no producir un sistema de traducción cuyo registro automático sea inadecuado para los usos prácticos esperados por la comunidad.

La estrategia adoptada comprende cuatro acciones:

- Estratificación del corpus por registro al momento del entrenamiento, con etiquetas explícitas de dominio (narrativo, religioso, didáctico, lexicográfico).
- Reporte separado de métricas spBLEU y chrF por dominio, evitando promedios globales que oculten el desempeño diferenciado.
- Tratamiento del corpus ESSJ (Evangelio según san Juan) como una fuente de dominio etiquetada explícitamente y susceptible de ablación, dado su volumen y su distancia respecto al registro contemporáneo.

- Definición de un alcance académico inicial del Componente B circunscrito al registro narrativo-didáctico, con la extensión al registro clínico y administrativo declarada como continuidad bajo la dirección del Programa Voces más allá del cierre académico de junio.

3. COMPONENTE A — INTERFAZ DE VALIDACIÓN COMUNITARIA

3.1 Naturaleza técnica del componente

El Componente A es la interfaz operativa del proyecto al momento de redacción de este reporte. Técnicamente, consiste en un sistema de tipo wrapper sobre un modelo de lenguaje grande pre-existente, en el cual la traducción no se produce mediante un modelo NMT específicamente entrenado, sino mediante prompt engineering con augmentación documental: la oración fuente es enviada al modelo junto con recursos lingüísticos curados (entradas de diccionario, ejemplos de gramática, pasajes paralelos relevantes) en el contexto de la solicitud, y se solicita al modelo producir una traducción fundamentada en dicha documentación.

En terminología técnica estándar, el Componente A corresponde a una configuración de in-context learning con grounding sobre documentación lingüística del bribri. El sistema opera sin entrenamiento de pesos, sin GPU local y sin actualización paramétrica de ningún modelo; su funcionamiento depende de llamadas a API de un proveedor externo de modelo de lenguaje y de la capa curada de inyección de contexto mantenida por el equipo de implementación de CENIA.

3.2 Recursos lingüísticos integrados como contexto

El Componente A integra como material contextual de prompt el conjunto de documentos descritos en la Tabla 1, con énfasis en los recursos de mayor densidad léxica y gramatical: el Diccionario de mitología bribri, la Gramática de Jara Murillo y los recursos didácticos del Sé'ttö' bribri ie. La selección de pasajes integrados al prompt varía según la naturaleza del enunciado de entrada, en una lógica de retrieval-augmented prompting orientada a balancear la cobertura léxica con las restricciones de ventana de contexto del modelo subyacente.

3.3 Mecanismo de retroalimentación humana

La interfaz incorpora un canal estructurado de retroalimentación que permite a los hablantes nativos: primero, calificar cada traducción con una señal binaria (aprobación o rechazo); segundo, introducir correcciones en lenguaje natural sobre la traducción propuesta. Estas correcciones son almacenadas en el sistema para análisis posterior y constituyen una fuente primaria de datos para: el refinamiento iterativo de la capa de prompts del Componente A; la depuración del corpus de entrenamiento del Componente B; y la construcción del conjunto de evaluación cualitativa por hablantes nativos.

3.4 Validación preliminar en territorio

Una validación preliminar del Componente A fue realizada en las comunidades de Suretka y Kachabri durante el trabajo de campo del 3 al 5 de mayo de 2026. La descripción detallada de los hallazgos se presenta en la sección 5 de este reporte.

3.5 Posicionamiento en el ecosistema del proyecto

El Componente A cumple tres funciones simultáneas dentro del proyecto: primero, sirve como interfaz operativa de validación intercultural ante la comunidad, en cumplimiento del protocolo intercultural del Programa Voces y del principio de propiedad comunitaria establecido por ADITIBRI; segundo, opera como línea base de comparación técnica para el Componente B, permitiendo cuantificar el aporte específico del fine-tuning frente a una solución de prompt engineering sobre LLM frontera; tercero, constituye el canal de recolección de retroalimentación humana que alimenta el ciclo iterativo de ambos componentes. El Componente A es de autoría del equipo de implementación de CENIA en Chile y no constituye, por sí mismo, el entregable académico del Proyecto Integrador.

4. COMPONENTE B — MODELO NMT (CONTRIBUCIÓN ACADÉMICA)

4.1 Delimitación del aporte académico

El Componente B constituye la contribución técnica específica del equipo de Costa Rica (D. Leiva, I. Vargas) al ecosistema del Programa Voces, y es el entregable evaluable del presente Proyecto Integrador ante el Tecnológico de Monterrey. Su alcance es el diseño, fine-tuning, evaluación cuantitativa y cualitativa, y documentación bajo el ciclo CRISP-ML de un modelo de traducción automática neuronal Transformer para el par bribri-español, comparado de manera explícita con el Componente A como línea base de producción.

4.2 Selección de arquitectura

El modelo base seleccionado para el fine-tuning es NLLB-200 distilled-600M (Costa-jussà et al., 2022), versión destilada con 600 millones de parámetros del modelo No Language Left Behind, liberado por Meta AI bajo licencia CC-BY-NC-4.0. La justificación de selección frente a alternativas como mBART-50 o M2M-100 contempla cuatro criterios:

- Arquitectura encoder-decoder multilingüe preentrenada sobre más de 200 lenguas, con representaciones cross-lingüísticas robustas.
- Tamaño paramétrico compatible con fine-tuning sobre infraestructura de GPU disponible en CENIA dentro de la ventana operativa del proyecto.
- Pesos abiertos, coherentes con el principio de propiedad comunitaria del producto resultante establecido en el oficio ADITIBRI-SEC-OF-00019-2025.
- Permite una comparación metodológicamente válida con el Componente A, en tanto modelo de tamaño intermedio frente al LLM frontera utilizado por el wrapper.

El bribri no forma parte del conjunto de 200 lenguas originalmente soportadas por NLLB-200; el fine-tuning constituye, por tanto, una extensión a lengua nueva. Las estrategias de extensión a evaluar experimentalmente en la primera semana de entrenamiento son: full-parameter fine-tuning del modelo base, fine-tuning con adapters de bajo rango (LoRA), y prompt-tuning como condición de control.

4.3 Estrategia de tokenización

Se ha definido entrenar un tokenizador SentencePiece nuevo sobre el corpus consolidado bribri-español, con un tamaño de vocabulario objetivo en el rango de 8.000 a 16.000 unidades subléxicas, a determinar mediante experimentación inicial. La decisión a favor de un tokenizador propio en lugar de heredar el tokenizador BPE original de NLLB-200 responde a dos consideraciones técnicas:

- Los diacríticos ortográficos del bribri, particularmente los marcadores tonales y las vocales nasales, no están bien cubiertos por el inventario subléxico de NLLB optimizado para las lenguas mayoritarias de su corpus original.
- Un vocabulario subléxico más reducido y específico al par bribri-español mitiga el riesgo de sobreajuste dado el tamaño limitado del corpus y respeta la morfología aglutinante característica del bribri.

4.4 Plan de entrenamiento y cómputo

El fine-tuning del modelo será ejecutado sobre infraestructura de GPU provista por CENIA, en una ventana operativa programada entre el 20 de mayo y el 15 de junio de 2026. El tiempo estimado por experimento se ubica en el orden de 4 a 8 horas sobre una GPU A100 individual, según las dimensiones efectivas del corpus y la estrategia de extensión seleccionada. El plan experimental contempla:

- Línea base: fine-tuning de NLLB-200 distilled con hiperparámetros por defecto sobre el corpus completo estratificado.
- Búsqueda de hiperparámetros: barrido sobre tasa de aprendizaje, pasos de calentamiento (warmup) y suavizado de etiquetas (label smoothing).
- Ablación de aumento de datos: corrida adicional con back-translation a partir de texto monolingüe en español del dominio narrativo y educativo (Sennrich, Haddow y Birch, 2016).
- Ablación de dominio: corrida adicional excluyendo el corpus ESSJ para aislar el efecto del registro religioso arcaico sobre la calidad de traducción en otros registros.

4.5 Marco de evaluación

El marco de evaluación combina métricas cuantitativas automáticas y validación cualitativa con hablantes nativos, primero se conformará un corpus con varias frases extraídas del material indicado.

- spBLEU (Papineni et al., 2002): métrica cuantitativa de referencia, reportada por dirección de traducción y por dominio temático.
- chrF (Popović, 2015): métrica cuantitativa primaria, basada en F-score de n-gramas de caracteres. Su selección como métrica primaria, refinada respecto a Fase 1, responde a la evidencia de su mayor sensibilidad a la morfología aglutinante y a la estructura tonal del bribri, donde spBLEU castiga injustamente variaciones morfológicas válidas.
- Evaluación cualitativa: validación con hablantes nativos bribris mediante el mismo canal de retroalimentación operado por el Componente A, permitiendo comparación directa entre componentes sobre los mismos enunciados de prueba. Las categorías de validación son: apropiada, con observaciones, inadecuada.

La selección de chrF como métrica primaria, complementaria al spBLEU, constituye una precisión metodológica respecto a Fase 1, que mencionaba spBLEU, chrF y COMET. La métrica COMET se desestima en el alcance del Avance académico dado que requiere un modelo de evaluación preentrenado sobre datos de calidad bribri-español que no existe en la literatura disponible.

4.6 Framework de comparación con Componente A

Ambos componentes serán evaluados sobre el mismo conjunto de prueba (test set) estratificado por dominio y mantenido fuera del proceso de fine-tuning, con las mismas métricas spBLEU y chrF y el mismo protocolo de validación cualitativa. El análisis comparativo se articulará en torno a tres ejes:

- Calidad de traducción: medida con spBLEU y chrF cuantitativos, y con juicio humano cualitativo.
- Costo de cómputo y despliegue: estimación de costo por traducción, latencia y requisitos de infraestructura.
- Compatibilidad con el principio de soberanía comunitaria: análisis de viabilidad de operación del sistema bajo control y custodia comunitaria, considerando pesos abiertos versus dependencia de API externa.

Es metodológicamente reconocido y declarado explícitamente que el Componente B podría no superar al Componente A en el eje de calidad pura de traducción, particularmente porque la literatura reciente muestra que modelos de lenguaje grandes con grounding contextual son competitivos en escenarios de bajos recursos. La contribución académica del Componente B no se posiciona exclusivamente sobre la métrica de calidad sino sobre el análisis comparativo integral en los tres ejes, que es metodológicamente novedoso para el par bribri-español y de utilidad estratégica para el Programa Voces.

5. HALLAZGOS DEL TRABAJO DE CAMPO

Las semanas del 28 de abril al 5 de mayo concentraron la fase de articulación interinstitucional y de validación inicial en territorio. La Tabla 2 resume las interlocuciones desarrolladas, sus hallazgos principales y su articulación con el avance del proyecto.

Tabla 2 · Trabajo de campo y reuniones institucionales abril-mayo 2026.

Fecha	Interlocutor	Hallazgo principal y articulación con el proyecto
28 de abril, San José	Universidad de Costa Rica — Lingüistas especializados en lenguas indígenas costarricenses	Apertura de canal académico para validación lingüística continua y exploración de acceso a fuentes documentales no aún incorporadas al repositorio del proyecto (Krohn, Margery Peña).
28 de abril, San José	Instituto Tecnológico de Costa Rica	Articulación de colaboración técnica complementaria para aspectos de infraestructura tecnológica de despliegue comunitario y articulación con el ecosistema costarricense de tecnología educativa.
29 de abril, San José	Fondo de Población de las Naciones Unidas (UNFPA)	Alineación del proyecto con agendas internacionales de derechos lingüísticos y poblaciones indígenas. Exploración de canales complementarios de sostenibilidad financiera para la continuidad del proyecto más allá del cierre académico.
3-5 de mayo, Suretka y Kachabri	Comunidad Bribri de Talamanca	Presentación del Componente A a la comunidad. Activación de los mecanismos de retroalimentación humana. Confirmación operativa del principio de apropiación comunitaria. Observación de interés sostenido por parte de hablantes nativos de distintas edades en el uso de la herramienta.
5 de mayo, San José	Caja Costarricense de Seguro Social (CCSS)	Articulación del caso de uso clínico para traducción bribri-español en contextos de atención de salud, particularmente para adultos mayores monolingües. Confirmación de interés institucional; la adopción institucional efectiva queda supeditada a umbrales de calidad que exceden el alcance del entregable académico.

5.1 Implicaciones técnicas y metodológicas

El conjunto del trabajo de campo refuerza tres decisiones técnicas y metodológicas que orientan la ejecución del Componente B:

- Priorización del canal de validación cualitativa con hablantes nativos por sobre la optimización ciega de spBLEU. La retroalimentación recibida en Suretka y Kachabri confirma que el criterio de éxito para la comunidad es la apropiación cultural de la traducción, no su métrica automática.
- Estratificación del conjunto de prueba por registro, con visibilidad explícita en el reporte final de los dominios donde el sistema alcanza calidad operativa y de los dominios donde aún no la alcanza. Esta transparencia es metodológicamente necesaria y, además, intercultural y políticamente requerida por el protocolo del Programa Voces.

- Continuidad del ciclo iterativo con la comunidad más allá del cierre académico de junio, bajo la dirección del Programa Voces y la custodia de ADITIBRI, conforme a lo establecido en el oficio ADITIBRI-SEC-OF-00019-2025 y la carta del Programa Voces al Tecnológico de Monterrey (Anexos A y B del informe de Fase 1).

6. RIESGOS Y DEPENDENCIAS

La Tabla 3 enumera los riesgos técnicos y operativos identificados a la fecha de este reporte, con su evaluación de probabilidad e impacto y la estrategia de mitigación adoptada.

Tabla 3 · Registro de riesgos del Avance 1.

Riesgo	Probabilidad / Impacto	Mitigación
Calidad de alineación oración-por-oración insuficiente desde los documentos paralelos extractuales	Alta / Alto	Doble pipeline de alineación (hunalign + LASER multilingüe) y revisión manual estratificada con UCR sobre muestra representativa.
Sesgo de dominio del corpus (sobre-representación religiosa y narrativa)	Alta / Medio	Estratificación explícita por dominio, reporte de métricas por registro, ablación del corpus ESSJ, declaración de alcance académico circunscrito a registro narrativo-didáctico.
Disponibilidad efectiva de GPU CENIA dentro de la ventana mayo-junio	Media / Alto	Solicitud formal anticipada de ventana de cómputo con buffer de 4 días; preparación de fallback sobre cómputo externo (Google Colab Pro o equivalente) en caso de bloqueo.
OCR de bribri sobre los documentos escaneados con calidad insuficiente para corpus de entrenamiento	Media / Medio	Entrenamiento de modelo Tesseract específico sobre fonts y diacríticos bribri, validación manual estratificada, exclusión de fragmentos con bajo umbral de confianza.
Componente B no logre superar al Componente A en métrica pura de calidad	Media / Bajo	Posicionamiento académico del aporte sobre el análisis comparativo en los tres ejes (calidad, costo, soberanía), no exclusivamente sobre superioridad métrica.
Brecha de documentos primarios prometidos en Fase 1 (Krohn, Margery Peña, MEP)	Media / Medio	Plan de recuperación con tres vías paralelas (UCR, MEP, CENIA); declaración explícita en este reporte de la brecha y de la base de corpus efectivamente disponible.

7. CRONOGRAMA AJUSTADO AL CIERRE ACADÉMICO

El cronograma se actualiza respecto a la sección 4.2 de Fase 1 para reflejar el marco híbrido y el plan específico del Componente B sobre la ventana operativa confirmada con CENIA. Se conserva el principio metodológico de Fase 1 según el cual el ritmo del trabajo intercultural con la comunidad no se subordina al calendario académico; lo que se compromete al cierre

académico es el entregable evaluable del Componente B, no el lanzamiento público del sistema.

Tabla 4 · Cronograma del Componente B hasta el cierre académico de junio de 2026.

Periodo	Fase CRISP-ML	Actividad principal y entregable comprometido
12-17 de mayo	Preparación de datos	Extracción y normalización del corpus de documentos con texto seleccionable (Gramática, Sé'ttö', I ttè, Ditsò rukuò, Francisco García, ESSJ). Solicitud formal de ventana de cómputo a CENIA. Entregable: corpus normalizado v0.
18-24 de mayo	Preparación de datos	OCR sobre documentos escaneados y alineación oración por oración. Entrenamiento del tokenizador SentencePiece. Entregable: corpus paralelo congelado v1 con estratificación por dominio.
25-31 de mayo	Modelado	Línea base de fine-tuning sobre NLLB-200 distilled-600M. Primeras corridas y diagnóstico de convergencia. Entregable: modelo línea base con spBLEU/chrF preliminares.
1-7 de junio	Modelado	Búsqueda de hiperparámetros y ablaciones (back-translation, exclusión ESSJ). Entregable: modelo candidato versionado con reporte de experimentación.
8-14 de junio	Aseguramiento de calidad	Evaluación cuantitativa spBLEU/chrF por dirección y dominio. Validación cualitativa con hablantes nativos vía canal de retroalimentación. Comparación con Componente A. Entregable: reporte de evaluación comparada.
15-21 de junio	Refinamiento	Iteración de cierre académico sobre hallazgos de evaluación. Documentación técnica y metodológica completa bajo CRISP-ML. Entregable: modelo final versionado y documentado.
22-28 de junio	Cierre	Reporte final del Proyecto Integrador, presentación académica y transferencia formal al Programa Voces y a ADITIBRI. Entregable: reporte final, demo comparada y presentación.

Tal como se documentó en la sección 4.3 de Fase 1, el cierre académico de junio corresponde al fin del ciclo del Proyecto Integrador, no al fin del Programa Voces. La continuidad operativa del traductor más allá de junio queda bajo la dirección del Programa Voces y la custodia de ADITIBRI, conforme a los instrumentos formales documentados en los Anexos A y B de Fase 1.

8. BIBLIOGRAFÍA

Las referencias se presentan en formato APA 7ª edición.

Constenla Umaña, A. (1981). Comparative Chibchan Phonology [Tesis doctoral, University of Pennsylvania]. ProQuest Dissertations Publishing.

Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia Gonzalez, G., Hansanti, P., Hoffman, J., ... Wang, J. (2022). No language left behind: Scaling human-centered machine translation. arXiv. <https://arxiv.org/abs/2207.04672>

- Instituto Nacional de Estadística y Censos. (2011). X Censo Nacional de Población y VI de Vivienda 2011: Territorios indígenas. INEC Costa Rica.
- Jara Murillo, C. V. (1993). *I ttè: Historias bribris*. Editorial de la Universidad de Costa Rica.
- Jara Murillo, C. V. (2018). *Gramática de la lengua bribri*. E-Digital ED.
- Jara Murillo, C. V., & García Segura, A. (1997). *Kó Késka: El lugar del tiempo. Historias y otras tradiciones orales del pueblo bribri*. Editorial de la Universidad de Costa Rica.
- Jara Murillo, C. V., & García Segura, A. (2013). *Sé'ttò' bribri ie: Hablemos en bribri*. E-Digital ED.
- Mager, M., Gutiérrez-Vasques, X., Sierra, G., & Meza-Ruiz, I. (2018). Challenges of language technologies for the indigenous languages of the Americas. En *Proceedings of the 27th International Conference on Computational Linguistics* (pp. 55–69). Association for Computational Linguistics.
- Margery Peña, E. (1989). *Diccionario fraseológico bribri-español, español-bribri*. Editorial de la Universidad de Costa Rica.
- Ortega, J. E., Castro Mamani, R., & Cho, K. (2020). Neural machine translation with a polysynthetic low resource language. *Machine Translation*, 34(4), 325–346.
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. En *Proceedings of the 40th Annual Meeting of the ACL* (pp. 311–318).
- Popović, M. (2015). chrF: Character n-gram F-score for automatic MT evaluation. En *Proceedings of the Tenth Workshop on Statistical Machine Translation* (pp. 392–395). Association for Computational Linguistics.
- Sánchez Avendaño, C. (2025). *La traducción de Guillermo Gabb del Evangelio según san Juan al bribri y su contexto de producción. Volumen 1: Edición comentada y procesamiento lingüístico del texto*. Centro de Investigación en Identidad y Cultura Latinoamericanas, Universidad de Costa Rica.
- Sennrich, R., Haddow, B., & Birch, A. (2016). Improving neural machine translation models with monolingual data. En *Proceedings of the 54th Annual Meeting of the ACL* (pp. 86–96). Association for Computational Linguistics.
- UNESCO. (2010). *Atlas of the World's Languages in Danger* (3rd ed.). UNESCO Publishing.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems* (Vol. 30, pp. 5998–6008). Curran Associates.