

TECNOLÓGICO DE MONTERREY

Maestría en Inteligencia Artificial Aplicada

PROYECTO INTEGRADOR

**Traducción Automática Neuronal para la Preservación
de la Lengua Bribri en Riesgo de Extinción**

*Proyecto Voces Bribri — Sistema NMT Bribri-Español mediante Arquitecturas
Transformer*

Daniel Leiva

*Encargado Regional CR, Proyecto
Voces
A01795876*

**Israel Agustín Vargas
Monroy**

*Estudiante, M.Sc. IAA
A01796556*

Patrocinador: Centro Nacional de Inteligencia Artificial (CENIA), Chile

2025

DATOS GENERALES DEL PROYECTO

1. Título del Proyecto

Título	Traducción Automática Neuronal para la Preservación de la Lengua Bribri en Riesgo de Extinción: Desarrollo de un Sistema NMT Bribri-Español mediante Arquitecturas Transformer para Lenguas de Bajos Recursos
---------------	---

El título refleja los tres ejes centrales del proyecto: (1) la metodología técnica — traducción automática neuronal basada en Transformers —, (2) el par lingüístico de interés — Bribri-Español —, y (3) el propósito institucional y social — la preservación de una lengua indígena costarricense clasificada como en riesgo de extinción. La inclusión del término low-resource languages en el título responde a la categorización internacional del Bribri dentro de la literatura de PLN, facilitando la identificación del proyecto en repositorios académicos.

2. Empresa / Institución

Institución	Centro Nacional de Inteligencia Artificial (CENIA)
--------------------	--

El Centro Nacional de Inteligencia Artificial (CENIA) es el principal centro de investigación y desarrollo en inteligencia artificial de Chile, fundado en 2021 en el marco del programa de centros de excelencia del gobierno chileno. CENIA lidera Proyecto Voces en colaboración con la Pontificia Universidad Católica de Chile y el Tecnológico de Monterrey, actuando como entidad coordinadora de los recursos computacionales, la infraestructura de entrenamiento de modelos y la dirección científica del proyecto.

El desafío que motiva la intervención es la ausencia de herramientas digitales de traducción automática para el par lingüístico Bribri-Español. Esta carencia limita severamente la transmisión intergeneracional de la lengua, restringe el acceso de la comunidad Bribri a servicios y contenidos en su idioma nativo, y reduce las posibilidades de documentación y revitalización lingüística asistida por tecnología (Gómez-Rendón, 2017; Mager et al., 2018).

3. Sector Industrial

Clasificación SCIAN	541720 — Investigación y desarrollo en ciencias naturales y exactas
Sistema de referencia	Sistema de Clasificación Industrial de América del Norte (SCIAN), INEGI

La actividad principal de CENIA corresponde a la generación sistemática de conocimiento científico y al desarrollo de tecnología en el campo de la inteligencia artificial, con aplicaciones en procesamiento de lenguaje natural, visión computacional y sistemas de aprendizaje automático. Esta actividad encuadra directamente en el código SCIAN 541720, que agrupa los establecimientos dedicados a la investigación y el desarrollo experimental en ciencias naturales,

exactas e ingeniería. La clasificación es consistente con la naturaleza del proyecto, el cual produce modelos computacionales, corpus lingüísticos anotados y metodologías de procesamiento para lenguas de bajos recursos.

4. Lugar de Aplicación

País	Costa Rica
Provincia / Cantón	Limón / Talamanca
Comunidad	Suretká, Territorio Indígena Bribri de Talamanca
Área / Departamento	Proyecto Voces — Unidad de Lenguas Indígenas en Riesgo
Sede institucional	CENIA, Santiago, Chile (coordinación central)

El trabajo de campo del proyecto se concentra en el Territorio Indígena Bribri de Talamanca, ubicado en el cantón de Talamanca, provincia de Limón, en la región fronteriza entre Costa Rica y Panamá. Suretká es una de las comunidades de mayor densidad poblacional Bribri en la región y constituye el principal nodo de coordinación con la Asociación de Desarrollo Integral del Territorio Indígena Bribri de Talamanca, entidad con la que el proyecto mantiene vínculos de colaboración para la validación cultural y lingüística de los recursos generados.

El territorio Bribri-Cabécar de Talamanca fue declarado Reserva de la Biosfera La Amistad por la UNESCO en 1982 y constituye una de las regiones de mayor diversidad lingüística y cultural de Centroamérica. La lengua Bribri, perteneciente a la familia lingüística Chibcha, es hablada por aproximadamente 12,000 personas según estimaciones del Censo Nacional 2011 (INEC, 2011), aunque estudios más recientes sugieren una reducción en el número de hablantes activos, particularmente entre las generaciones más jóvenes (Jara Murillo, 2018).

Desde Costa Rica, Daniel Leiva actúa como encargado regional del proyecto, coordinando la recopilación de datos lingüísticos, el establecimiento de alianzas con entidades académicas locales — entre ellas la Universidad de Costa Rica (UCR) — y la articulación con las comunidades indígenas para garantizar que el desarrollo tecnológico respete los principios de soberanía lingüística y beneficio comunitario.

5. Patrocinador / Sponsor

Institución	Centro Nacional de Inteligencia Artificial (CENIA), Chile
Nombre del sponsor	Carlos Aspillaga

CENIA provee la infraestructura computacional, el acceso a clústeres de entrenamiento de modelos de lenguaje, y el marco institucional que valida el proyecto ante instancias académicas e internacionales. Como patrocinador, CENIA asume la responsabilidad de facilitar los recursos necesarios para la ejecución de las fases de entrenamiento, evaluación y ajuste fino de los modelos NMT desarrollados en el proyecto.

6. Datos del Sponsor

Cargo / Puesto	Director del Programa Voces
Correo institucional	carlos.aspillaga@cenia.cl

7. Dominio de Aplicación

Dominio seleccionado	Procesamiento de Lenguaje Natural (PLN)
Técnica principal	Aprendizaje supervisado — Traducción Automática Neuronal (NMT)
Arquitectura	Transformer (seq2seq con mecanismo de atención)

El dominio de Procesamiento de Lenguaje Natural es el que describe con mayor precisión el enfoque técnico del proyecto. Específicamente, el proyecto aborda el problema de la traducción automática neuronal (Neural Machine Translation, NMT) para el par lingüístico Bribri-Español, utilizando arquitecturas de tipo Transformer con mecanismos de atención multi-cabeza (Vaswani et al., 2017). Este enfoque se enmarca en el aprendizaje supervisado, dado que los modelos son entrenados sobre corpus paralelos bilingües anotados.

La principal complejidad técnica del proyecto reside en la naturaleza de lengua de bajos recursos (low-resource language) del Bribri. A diferencia de lenguas con amplia presencia digital — como el inglés o el español —, el Bribri cuenta con un corpus paralelo extremadamente limitado: las fuentes disponibles incluyen el diccionario bilingüe compilado por Haakon Krohn, materiales del Ministerio de Educación Pública de Costa Rica (MEP), documentación lingüística académica producida por investigadores como Carla Victoria Jara Murillo y Anne Guillon, y recursos recopilados en el marco del propio Proyecto Voces (Jara Murillo & García Segura, 1997; Margery Peña, 1989).

Para mitigar la escasez de datos, el proyecto explora estrategias de transferencia de aprendizaje (transfer learning), ajuste fino de modelos preentrenados en lenguas tipológicamente relacionadas de la familia Chibcha, y técnicas de aumento de datos (data augmentation) aplicadas a corpus lingüísticos de lenguas indígenas de bajos recursos. Esta combinación de enfoques sitúa al proyecto en la frontera de la investigación aplicada en PLN para lenguas indígenas latinoamericanas, un área de creciente relevancia en la comunidad internacional de NLP (Mager et al., 2018; Ortega et al., 2020).

Referencias

- INEC. (2011). X Censo Nacional de Población y VI de Vivienda 2011. Instituto Nacional de Estadística y Censos de Costa Rica.
- Jara Murillo, C. V. (2018). El bribri: Lengua en peligro. *Revista de Filología y Lingüística de la Universidad de Costa Rica*, 44(1), 15–32.
- Jara Murillo, C. V., & García Segura, A. (1997). *Se'ttö': Hablemos bribri*. Editorial de la Universidad de Costa Rica.
- Margery Peña, E. (1989). *Diccionario fraseológico bribri-español, español-bribri*. Editorial de la Universidad de Costa Rica.
- Mager, M., Kann, K., Coto-Solano, R., & Rendón-Anaya, M. (2018). Challenges of language technologies for the indigenous languages of the Americas. *Proceedings of COLING 2018*.
- Ortega, J., Maldonado, A., & Mager, M. (2020). Neural machine translation for low-resource indigenous languages. *Proceedings of the 1st Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.